

Relatório Técnico — Clusterização de Clientes e Regras de Associação

Tópicos 1 — Business Intelligence · Trabalho 2

Outubro de 2026

1. Objetivo

Aplicar **aprendizagem por conjuntos (ensemble)** sobre o DW Organizacional construído no Trabalho 1:

1. **segmentar os clientes** pelo comportamento de compra (RFM + K-Means);
2. **descobrir regras de associação entre produtos dentro de cada segmento** (Apriori).

A motivação é simples: regras extraídas de todas as vendas de uma vez tendem a ser genéricas e dominadas pelo cliente mais comum. Segmentando primeiro, cada grupo revela os seus próprios padrões, e cada padrão já vem com o público a quem se destina.

Entregável	Arquivo
Código (análise)	<code>notebook/clusterizacao_regras.ipynb</code>
DataMart para o fim (DDL e carga)	<code>DW_Docker/ddl/03_dm_crm.sql</code> , <code>DW_Docker/etl/07_dm_crm.sql</code>
Povoamento do BD	<code>DW_Docker/fontes/02_mercearia_movimento.sql</code>
Ambiente	<code>DW_Docker/docker-compose.yml</code> , <code>requirements.txt</code>

2. Escopo: por que só a base Mercearia

O DW integra duas fontes, mas a análise usa apenas a **Mercearia** (varejo). A **Northwind** foi avaliada e descartada pelos motivos abaixo:

Critério	Northwind (B2B)	Mercearia (varejo)
Pedidos / clientes / produtos	830 / 89 / 77	19.638 / 149 / 30
Itens por pedido	2,6	3,1
Par de produtos mais comum	8 pedidos (1,0%)	3.960 cupons (20,2%)
Silhueta do K-Means (melhor k)	0,37 — sem grupos naturais	0,68

Na Northwind, os pedidos são reposições de estoque de distribuidores. São poucos itens por pedido, num catálogo grande, e as combinações quase não se repetem: nenhum par de produtos chega a 1% dos pedidos. Subindo para o nível de categoria também não há associação, pois nenhum dos 28 pares de categorias tem lift acima de 1 (máx. 0,97). Com tão poucas coincidências, o Apriori ou não encontra nada ou “encontra” regras sustentadas por 1 ou 2 pedidos, que são acaso e não padrão. Além disso, os clientes formam um contínuo, sem grupos naturais. A técnica pressupõe cestas recorrentes, e esse é o cenário do varejo.

3. Dados

3.1 Povoamento do BD

O movimento de vendas original da Mercearia (Trabalho 1) sorteava cliente e produtos de forma **independente**. Assim, nenhuma cesta tinha padrão e qualquer regra sairia com lift ≈ 1 . Para este trabalho, o script `fontes/02_mercearia_movimento.sql` foi reescrito: cada cliente recebe um **perfil de compra**, que define

- a **frequência** de visitas (com variação individual de $\pm 20\%$ e mais movimento em dezembro); e
- as **missões de compra**: cestas típicas que ocorrem em cada visita com certa probabilidade, sempre acompanhadas de itens avulsos (ruído).

Perfil	Clientes	Visitas	Missões (exemplos)
Café da manhã	30	~3,5 por semana	pão + presunto; café + leite + biscoito; aveia + banana
Família com bebê	30	~1,5 por semana	fralda + sabonete + leite; biscoito + suco + chocolate; pizza + refrigerante
Churrasco	30	~0,75 por semana, sexta a domingo	picanha + cerveja + sal; cerveja + chips; tilápia + refrigerante
Compra do mês	30	~1 por mês	arroz + feijão + óleo; macarrão + molho; detergente + sabonete; café + farinha
Ocasional	29	poucas, e pararam de comprar	itens de conveniência soltos

O período vai de 01/10/2024 a 28/09/2026, com 19.638 cupons e 61.213 itens. O script é determinístico (`setseed`), então cada execução gera os mesmos dados. **O perfil não é carregado no DW**: ele fica só na tabela `gabarito_perfil` do banco de origem, usada no fim para validar se a clusterização o redescobriu.

3.2 DataMart `dm_crm`

Os DataMarts do Trabalho 1 agregam as vendas sem o cliente individual (minimização por LGPD) e por isso não servem aqui. Foi criado o DataMart `dm_crm` , carregado **somente a partir do schema `dw`** :

```
Fontes → DW ( dw.fato_vendas , dw.dim_cliente , dw.dim_produto ) → dm_crm → notebook (K-Means + Apriori) → dm_crm (resultados)
```

Tabela	Grão	Uso
<code>dim_cliente , dim_produto</code>	cliente / produto de negócio	consolidam as versões SCD2 do DW na versão atual
<code>fato_cesta</code>	1 produto em 1 cupom	transações do Apriori
<code>fato_cliente_rfm</code>	1 cliente	entrada do K-Means: recência, frequência, ticket médio
<code>cliente_cluster , regra_associacao</code>	cliente / regra	resultados, gravados pelo notebook

A validação do ETL foi ampliada: a receita e o número de cupons do `dm_crm` precisam bater com o DW. Se não baterem, a carga é abortada. O cliente aparece só pela chave substituta e pelo pseudônimo do DW (ex.: `Cliente MC-00042`).

4. Método

4.1 Segmentação: RFM + K-Means

RFM descreve cada cliente por três números: **Recência** (dias desde a última compra), **Frequência** (nº de cupons) e **Monetário**. Como M usamos o **ticket médio**. O valor total seria praticamente $F \times \text{ticket}$ e repetiria a informação de F.

O **K-Means** agrupa clientes próximos no espaço R-F-M, por distância euclidiana. Por isso as variáveis passam por dois tratamentos:

1. **redução de assimetria**: raiz quadrada em R (assimetria moderada) e logaritmo em F e M (assimetria forte, com poucos clientes muito acima dos demais);
2. **padronização (z-score)**: média 0 e desvio 1, para nenhuma variável dominar a distância.

O número de grupos **k** foi escolhido entre 2 e 8 pelo **método do cotovelo** (inércia, a soma das distâncias ao centro do grupo) e pela **silhueta** (de -1 a 1: o quanto cada cliente está mais perto do próprio grupo que do vizinho). A regra foi a maior silhueta com $k \geq 3$, porque $k = 2$ só separaria “bons” de “ruins”.

4.2 Associação: Apriori

Cada cupom é uma **cesta**. O algoritmo **Apriori** encontra os conjuntos de produtos frequentes e, a partir deles, regras **A** → **B**, avaliadas por:

Métrica	Significado	Limite usado
Suporte	% das cestas com A e B juntos	$\geq 5\%$ (e ≥ 5 cestas)
Confiança	entre as cestas com A, % que também têm B	$\geq 40\%$
Lift	$\text{confiança} \div \text{\% de cestas com B}$; 1 = acaso	$\geq 1,2$


Usamos **pares** de produtos ($A \rightarrow B$), que viram ação direta: “quem leva A recebe oferta de B”. Como $A \rightarrow B$ e $B \rightarrow A$ têm o mesmo lift, mantemos só o sentido de maior confiança.

4.3 O ensemble

As mesmas regras foram mineradas **na base inteira** e **em cada cluster**, com os mesmos limites. A comparação mostra o que a segmentação acrescenta. Ferramentas: Python com `pandas`, `scikit-learn` (K-Means, silhueta), `mlxtend` (Apriori) e `matplotlib`.


5. Resultados

5.1 Clusters




Escolha de k: a silhueta tem o máximo em k = 5, onde o cotovelo também se estabiliza

Com **k = 5** a silhueta chega a **0,68**, o maior valor da faixa (acima até de k = 2) e um indicador de grupos bem separados. Os clusters foram numerados do mais ao menos frequente e nomeados pelo comportamento RFM. O RFM não sabe nada sobre produtos:



Perfil RFM dos clusters (medianas) e participação na receita

Cluster	Cientes	Recência	Frequência	Ticket médio	% receita	Comportamento
Diários	30	1 dia	383	R\$ 49,90	39,5%	vêm quase todo dia, ticket baixo
Frequentes	30	3 dias	162,5	R\$ 84,20	29,3%	1 a 2 vezes por semana
Semanais	30	3,5 dias	83	R\$ 131,60	22,1%	~1 vez por semana, ticket alto
Mensais	30	16,5 dias	24,5	R\$ 162,80	8,6%	~1 vez por mês, a maior compra
Inativos	29	323 dias	7	R\$ 32,90	0,5%	poucas compras, sumiram



Cada cluster em destaque no plano frequência × ticket médio

Validação. Cruzando os clusters com o gabarito, a **pureza foi de 100%**: os 149 clientes caíram no cluster correspondente ao seu perfil (Diários = Café da manhã, Frequentes = Família com bebê, Semanais = Churrasco, Mensais = Compra do mês, Inativos = Ocasional), sem o modelo nunca ter visto o perfil. O resultado é tão limpo porque os dados são simulados e os perfis bem separados. Com dados reais, a fronteira entre grupos seria mais difusa.

5.2 Regras: base inteira × por cluster

Grupo	Cestas	Regras	Só no cluster	Regra de maior lift
Base inteira	19.638	17	—	Picanha → Cerveja (7,5)
Diários	11.345	7	0	Banana → Aveia (3,5)
Frequentes	4.910	9	4	Sorvete → Pizza congelada (3,2)
Semanais	2.411	8	7	Refrigerante → Tilápia (3,9)
Mensais	760	7	7	Farinha de trigo → Café (1,6)
Inativos	212	0	—	—

Exemplos de regras por cluster (suporte / confiança / lift):

Cluster	Regra	Sup.	Conf.	Lift
Diários	Presunto → Pão francês	32,6%	90%	1,63
Diários	Biscoito → Café	17,9%	84%	2,29
Frequentes	Leite → Fralda	26,0%	86%	1,89
Frequentes	Suco de laranja → Biscoito	28,0%	81%	2,13
Semanais	Sal → Picanha	33,6%	94%	1,66
Semanais	Fósforo → Picanha	22,6%	90%	1,58
Mensais	Molho de tomate → Macarrão	53,9%	89%	1,45
Mensais	Vassoura → Detergente	20,5%	91%	1,49

O que a segmentação acrescentou:

- 1. A base inteira só enxerga o cliente dominante.** Os Diários geram 58% dos cupons, e 11 das 17 regras globais são da cesta de café da manhã deles. As 7 regras do cluster Diários já estavam na base inteira.
- 2. 18 regras só aparecem segmentando.** A compra de abastecimento dos Mensais está em apenas 4% dos cupons e não atinge o suporte mínimo na base inteira. Dentro do cluster, ela aparece inteira.

3. **O mesmo produto muda de parceiro.** O leite vai com café e pão nos Diários e com fralda e sabonete nos Frequentes. O sabonete vai com fralda nos Frequentes e com detergente nos Mensais. O refrigerante vai com pizza nos Frequentes e com tilápia nos Semanais.
4. **A base inteira cria regras falsas e infla o lift.** 4 das 17 regras globais (ex.: banana → pão, café → pão) não se confirmam em nenhum cluster. Os dois produtos são do mesmo tipo de cliente, mas de cestas diferentes. Pelo mesmo motivo, picanha → cerveja tem lift **7,5** na base inteira e **1,3** dentro dos Semanais: o valor global mede principalmente que os dois produtos são comprados pelo mesmo tipo de cliente, e não a afinidade entre eles.
5. **Confiança alta nem sempre é associação.** Nos Mensais, o arroz está em 85% das cestas. Ele é a base da compra, e por isso nenhuma regra com ele passa do lift 1,2: o máximo possível seria $1 \div 0,85 \approx 1,18$.
6. **Inativos não têm regras**, porque as cestas são pequenas e sem padrão.

5.3 Ações sugeridas

Cluster	Ação
Diários	combo café da manhã (pão + presunto; café + leite + biscoito)
Frequentes	kit lanche infantil; oferta de fralda junto de leite e sabonete
Semanais	kit churrasco às sextas (picanha + sal + fósforo + cerveja)
Mensais	lista de compra do mês com delivery (massas + molho; limpeza)
Inativos	reativação (cupom de retorno), não venda cruzada

6. Como executar

```
cd DW_Docker
docker compose up -d          # PostgreSQL (porta 5434) + ETL até o dm_crm
docker compose logs etl       # conferir a validação da carga
cd ..
python3 -m venv .venv && .venv/bin/pip install -r requirements.txt
cd notebook && ../.venv/bin/jupyter notebook clusterizacao_regras.ipynb
```

O notebook lê o `dm_crm`, gera as figuras em `relatorio/figuras/` e grava os clusters e as regras de volta no banco.

7. Limitações

- **Dados simulados.** Os perfis foram embutidos no povoamento, por isso os clusters saem muito nítidos. O mérito da validação é mostrar que o pipeline **recupera** uma estrutura que de fato existe, sem tê-la visto. Em dados reais, a pureza seria menor.
- **RFM descreve comportamento, não preferência.** Aqui os dois andam juntos (cada perfil tem frequência e ticket próprios). Num cenário em que clientes com o mesmo RFM comprassem coisas diferentes, valeria acrescentar variáveis de mix de categorias.

- **Só pares de produtos.** Regras com mais itens ($\{\text{pão, presunto}\} \rightarrow \text{leite}\}$) foram deixadas de fora, para manter a leitura simples.
- **Parâmetros fixos.** Os limites de suporte, confiança e lift foram definidos uma vez, para a base inteira e para os clusters. Clusters pequenos, como o de Inativos, ficam naturalmente sem regras.